

GAZİ ÜNİVERSİTESİ
BİLGİSAYAR MÜHENDİSLİĞİ



LİTERATÜR TARAMASI

Mobil Akıllı Bitki Yaprak Hastalığı Tespit Uygulaması

BM495 BİLGİSAYAR PROJESİ-I

Kelime sayısı: 2366

181180052 KEZİBAN NUR KÖLE

191180094 MERJEM KESTEN

EKİM 2022

1. Giriş

Bitkiler dünyamızın büyük bir alanını kapsayan ve yaşam döngüsü başta olmak üzere bir çok alanda hayatımızda olan canlılardır. Özellikle besin kaynağı olarak yetiştirilen bitkilerin sağlığı ya da hastalığının erken tespiti ve tedavisi oldukça önemlidir. Büyük zirai alanlarda hastalık tespitini teknolojik yardım olmadan yapabilmek oldukça zor ve maliyetlidir. Bu yüzden gerçekleştirmek istediğimiz ‘Bitkilerde yaprak hastalığı tespiti mobil uygulaması’ projemiz için daha önce yapılan projeleri, makaleleri inceledik. Sonucunda literatür taraması çalışması yaptık.

Bahsettiğimiz bu çalışmamız 4 parçadan oluşmaktadır. Birincisi Giriş, genel bir tanıtım yaptığımız yer; ikincisi İlgili çalışmalar kısmı, burada 11 makale inceledik ve her makalenin başlığı burada bir alt başlık olarak verilmiştir. İncelediğimiz makaleleri üç gruba ayırabiliriz onlar da bitki hastalıklarında kullanılan yapay zeka modelleri, mobil uygulamalarında kullanılan deep learning modelleri ve onu gerçekleştirmek için gereken tüm gereksinimler ve son olarak mobil uygulamalarında kullanılan deep learning modelleri. Üçüncü kısımda makallerin okuma sonucunda neler öğrendik ve bundan biz nasıl bir sonuç çıkarttık. Son kısım ise makalelerin kaynakları ve kullandığımız diğer kaynaklar bulunmaktadır.

2. İlgili çalışmalar

2.1. Bitki Hastalıklarını Tespit Etmek İçin Kullanılan Yapay Zeka Modelleri

2.1.1. Plant Leaf Disease Detection and Classification Based on CNN with LVQ Algorithm

Bu makalede [9] domates yaprakları hastalıklarının tespit edilmesi ve sınıflandırılması için bir CNN Modeli ve Learning Vector Quantization (LVQ) algoritmasına dayalı yöntem sunulmaktadır. Renk bilgileri bitki yaprakları hastalık tespitinde önemlidir, aktif bir şekilde kullanılır. Kullandıkları modellerinde filtreler tek bir renk bileşeninden ziyade RGB renk bileşenlerine dayalı üç kanala uygulamışlardır. Bunun için PlantVillage veri setinden domates yaprakları görüntülerinin RGB bileşenlerine dayalı bir CNN modeli geliştirmişlerdir. Topolojisi ve uyarlanabilir modeli nedeniyle LVQ algoritmasını sınıflandırıcı (classifier) olarak seçmişlerdir. Deneysel sonuçlar önerilen yöntemin dört farklı domates yaprağı hastalığının etkili bir şekilde tanındığını doğrular. Sınıflandırma sonucu ise %86 doğruluk oranında olmuştur.

2.1.2. Performance of deep learning vs machine learning in plant leaf disease detection

Bu makale [2]'deki yazarlar, bitki yaprağı hastalık tespitinde normal makine öğrenimi ve derin transfer öğrenme tekniklerinin performansını değerlendirdiğinde, derin öğrenme tekniklerinin performansı, makine öğrenimi tekniklerinden üstün olduğunu gözlemlemişlerdir.

Bu çalışmada kullanılan veri seti, Pakistan, Sargodha'daki Pencap Hükümeti Narenciye Araştırma Merkezi ve uzmanların gözetiminde manuel olarak bir araya getirilmiştir. Veri setini toplam 609 hem hastalıklı hem de zararsız narenciye yaprakları ve meyvelerin fotoğraflarından oluşmakta daha sonra çalışmada en yaygın yaprak hastalıklarına göre kategorize edilmiştir. ML ve DL modelleri karşılaştırılmıştır ve sonuç olarak test edilen tüm DL modelleri daha başarılı olmuştur. VGG-16 modeli ise, %89,5 sınıflandırma doğruluğu ile diğer makine öğrenimi ve derin öğrenme tekniklerinden daha iyi performans göstermiştir.

2.1.3. An Improved Deep Residual Convolutional Neural Network for Plant Leaf Disease Detection

Bu makale[1]'deki yazarlar deep residual convolutional neural network modelini kullanarak yirmi iki farklı bitkinin yaprak hastalıklarını teşhis etmişlerdir. Bu modelin, yaprak hastalık tespiti için 197 katmanlı (layers) ResNet 197 adında yeni bir model tasarlamışlar ve geliştirmişlerdir. 103 tür sağlıklı ve hastalıklı fotoğraf içeren ve kullanılan dataset, yaygın yaprak hastalıklarını tanımlamak için çeşitli veri setlerinden derlenmiştir. Sınıflandırma tekniklerinin performansını tahmin etmek için en popüler ölçü olan AUC-ROC eğrisinde ResNet 197'nin değeri 0,98 ile 1,0 arasındadır ve diğer standart transfer öğrenme tekniklerinden daha yüksek olduğunu gözlemlemişlerdir. Sınıflandırma teknikleri, accuracy, precision, recall, ve F1-score genel performansını değerlendirmek için standart ölçülere göre hem diğer ResNet modelleriyle karşılaştırmış hem de diğer bitki yaprak hastalık tespitinde transfer öğrenme teknikleriyle karşılaştırılmışlardır. Her iki karşılaştırmada ResNet 197 test verilerinde ortalama %99,58 sınıflandırma doğruluğu (accuracy) elde etmişlerdir.

2.1.4. Plant Leaf Disease Detection Using Deep Learning

Bu çalışmada[3], 16 farklı bitki türünü ve bitki hastalıklarını tanımlamak ve tespit etmek için convolutional neural network kullanılmıştır. Plant Village veri kümesi de dahil olmak üzere, sağlıklı ve hastalıklı bitki yapraklarının kamuya açık 12.500 görüntüsü kullanılarak belirli bir hastalığı veri kümesinin geri kalanından ayırt edebilen bir derin öğrenme convolutional neural network modeli kullanarak eğitmiştir. Derin öğrenme modelini eğitmek için 50 dönem (epochs) kullanıldı ve sonunda %98 doğruluğa ulaşılmıştır. Model, rastgele görüntü örneklerinde test edildiğinde maksimum %99 doğruluk elde etmiştir.

2.1.5. Deep Learning Utilization in Agriculture: Detection of Rice Plant Diseases Using an Improved CNN Model

[4] Pirinç dünyada en çok üretilen bitkiler arasındadır. Bu yüzden bir hastalığı olduğunda %20 - 40 oranında pirinç üretimi kaybına yol açar. Bu yüzden bu hastalıkların görsel olarak erken tespit edilmesi gerekir. Bunu çiftçiler tek başlarına yapamayacakları için insansız hava araçlarına takılan makine öğrenimi algoritmaları ve nesnelerin interneti (IoT) ile bir çözüm sağlanabilir. Bu makalede[4] yazarlar, pirinç yaprağı hastalığının tespiti ve sınıflandırılması için Deep Convolutional Neural Network (DCNN) aktarım öğrenme tabanlı yaklaşımı önermişlerdir. Değiştirilen önerilen yaklaşım, değiştirilmiş VGG19 tabanlı bir aktarım öğrenme yöntemini içermiştir. Önerilen değiştirilmiş sistem altı farklı sınıfı doğru bir şekilde tespit edebilmiştir. En yüksek ortalama doğruluk oranı, normalleştirilmiş olmayan artırılmış (non - normalized augmented) veri seti kullanılarak %96.08 olmuştur. Karşılık gelen kesinlik, geri çağırma, özgülük ve F1 puanı sırasıyla 0.9620, 0.9617, 0.9921 ve 0.9616'dır. Önerilen değiştirilmiş yaklaşım, aynı veri seti veya eko literatüründe bildirilen benzer veri setleri kullanılarak benzer yaklaşımlara kıyasla önemli ölçüde daha iyi sonuçlar elde etmiştir.

2.2. Mobil Uygulamalarında Deep Learning Modelleri ve Gereksinimleri

2.2.1. A First Look at Deep Learning Apps on Smartphones

Araştırma ve gerçeklik arasında bir köprü olarak, derin öğrenme tekniklerinin gerçek akıllı telefonlarına nasıl uygulandığını anlamak için bu çalışmada[5] ilk deneysel araştırmayı statik araç kullanılarak gerçekleştirdiler. Bu çalışmada kullanılan tüm dataseti, en popüler 500 ücretsiz indirme olan 33 Google Play kategorisinin her birinden toplam 16.500 uygulamanın seçildiği Google Play Store'dan alınmıştır. Üç ay arayla farklı zamanlarda iki dataseti taramışlardı ve çalışma boyunca sonuçları karşılaştırdılar. TensorFlow, Caffe, TFLite ve diğer

iyi bilinen DL çerçeveleri, DL Sniffer tarafından tespit edilen 16 çerçeve arasındadır ve en sık kullanan TensorFlow (51) dir. Buna ek olarak, çerçeveleri kullanmayan DL programları da bulmuştur. Bulunan 21 çerçeveden 16'sı Android, Java veya C++ resmi dillerini kullanan Android platformunu destekler (çapraz derleme yoluyla yerel destek).

İkinci datasete göre toplamda 211 DL uygulaması var, yani 166'dan %27,1'lik bir artış gerçekleşmiştir. Görülebilenler, 211 DL uygulamasından 61'i (veya yaklaşık %29'u) fotoğraf kategorisine aittir ve tümü görüntü işleme için DL kullanır. Bulunan DL modellerinden %87,7'si CNN modelleri, %7,8'i ise RNN modelleridir. Güvenlik açısından ise, sonuçlara göre 120 DL modeli arasında 47 (%39,2) modelin obfuscated edildiğini ve 23'ünün (%19,2) modelin encrypted edildiğini göstermektedir.

2.3. Mobil Uygulamalarında Bitki Hastalıklarını Tespit Etmek İçin Kullanılan Deep Learning Modelleri

2.3.1. Multifunctional Platform And Mobile Application For Plant Disease Detection

İncelediğimiz makalenin[8] yazarları, tarım bitkilerinin hastalıklarının tespitini ve önlenmesini kolaylaştırmak için bitki hastalık tespiti için çok işlevli bir platform geliştirmişlerdir. PlantVillage'a bir alternatif bulamadılar, bu yüzden kendi hastalıklı yapraklar veritabanlarını oluşturdular, son halinde ise 15 sınıf ve toplam 611 yaprak fotoğrafı içermektedir. Doğruluğu önemli ölçüde artıran benzersiz bir Siamese aktarımı öğrenme tekniği oluşturmuşlardır. Bu modelin en iyi versiyonu, beş sınıflı testten daha az olan 150 dönem 15 sınıfın tamamında eğitimden sonra %86 test sınıflandırma doğruluğu elde etmişlerdir. KNN'nin sınıflandırıcı olarak kullanılmasının, doğruluktaki bu tür bir düşüşün kaynağı olabileceğini iddia etmişlerdir.

2.3.2. Tomato leaf segmentation algorithms for mobile phone applications using deep learning

Bu makalede[10], mobil uygulamalarda çekilen yaprak görüntüleri için otomatik arka plan çıkarma işlemini gerçekleştirmek üzere tamamen kıvrımlı sinir ağları (fully convolutional neural network) önermişlerdir. Mobil uygulama kullanım durumunda, hedef yaprak genellikle çiftçi tarafından yakalanan bir görüntüye baskın gelmiştir. Yaprak ayrıca diğer yapraklar, saplar, meyveler, toprak ve malç gibi çeşitli arka plan özellikleriyle çevrelenir. Segmentasyon ağının amacı, yalnızca hedef yaprağın kalması için bu arka plan özelliklerini kaldırmaktır.

Önerilen ağları eğitmek ve test etmek için bu senaryoyu temsil eden bir veri seti hazırlamışlardır. Bu, zorlu alan koşulları altında yakalanan 1,408 domates yaprağı görüntüsünden ve bunların ilgili gerçek topraklama maskelerinden oluşmuştur. 0.91'den fazla sınır F1 puanı üzerinden 0.96'den fazla ortalama ağırlıklı kesişme ile en son teknoloji ürünü yaprak görüntüsü segmentasyonu performansı bildirmişlerdir. Özellikle, önerilen segmentasyon ağları olan KijaniNet, 0.9766 puan alan tüm rakiplere kıyasla daha yüksek bir performans göstermiştir. Bu sayı, birleştirme ve 0.9439 sınır F1 puanı üzerinde ağırlıklı kesişme anlamına gelir. Önerilen teknik, rakip arka plan çıkarma algoritmalarının yerini almıştır ancak kullanıcı müdahalesi gerektirmemiştir ve hedef yaprağın oryantasyonu, şekli veya ışıklandırması üzerine sınırlamalar koymamıştır. Ayrıca tüm CNN modelleri, GPU'da çalışırken 0.12 sn'nin altında ve CPU'da çalışırken 2.1 sn'nin altında 256 x 256 piksel RGB görüntüsünün segmentasyonunu gerçekleştirebilir. Bu, rakip tekniklerden çok daha hızlıdır.

2.3.3. A Mobile-Based System for Detecting Plant Leaf Diseases Using Deep Learning

Doğrudan çiftçinin cep telefonundan fotoğraf çekebilen bulut için bir Evrişimsel Sinir Ağı (CNN) modeli geliştirdiler ve kullanıcı tarafında ve mobil uygulama CNN paradigmasının üzerine inşa edildi. Bitki hastalık dedektörü için dağıtılmış çalışma sistemi, kullanıcı tarafında mobil cihazlarda, bulut tarafında ise merkezi sunucularda yürütülen parçalar ile organize edilmiştir. Sistem üç layerden oluşmakta ML layer, Uygulama layer ve Kullanıcı layer. Bu projede[7] kullanılan veri seti için Kaggle, Plant Village ve Google Web Scraper gibi sitelerden sağlıklı ve hastalıklı bitki yapraklarının 96.000'den fazla açıklamalı fotoğrafını topladılar. Eğitilen CNN modelini mobil cihaza aktarmadan önce öğrenilen ağ mimarisi, ağırlıklar ve bias değerlerine göre IR modelini iyileştirdiler. En yaygın üç mahsul hastalığı türü olan kabuklanma, yanıklık ve çürüme için model, mısır yanıklığı, üzüm karası çürüklüğü ve elma kabuğu için sırasıyla %96, %98 ve %97'nin üzerinde doğruluklar elde etmişlerdir. Benzer yaprak fenolojileri nedeniyle zaman zaman domates ve patates hastalıklarını karıştırdığı için sistemleri mükemmel olmadığını belirttiler. Renk, büyüklük ve gölge yapısı gibi bitki fizyonomisinin bazı ortak özelliklerini paylaştıklarından, aynı türü etkileyen hastalıklar genellikle benzer semptomlar gösterir. CNN modeli ile yapılan sınıflandırma doğruluğu ve 38 hastalık sınıfı için tahmin süresi, %93,6'lık bir genel ortalama sınıflandırma doğruluğu elde etmişlerdi ve ortalama tahmin süresi 0.88 s olarak ölçülmüştür.

2.3.4. Cocoa Companion: Deep Learning-Based Smartphone Application for Cocoa Disease Detection

Bu makalede[6] arařtırmacılar -aynı zamanda uygulamayı geliřtirenler, kakao'ların üretimini engelleyen iki büyük hastalığın (Swollen Shoot ve Black Pod) erken algılanması ve teřhis edilmesi için ML tekniklerinin uygulanabileceğini ortaya koydular. Bu konu üzerine, bir mobil uygulama ile çiftçilerin kakao podunun fotoğrafını çekmesi ve uç bulut hizmeti sayesinde gerçekteřen tanılama için sisteme yükleme yapmasını sağlamak üzere ML teknikleriyle tasarlamışlardır. Veri seti olarak da bu iki türde kakao hastalığından ve sağlıklı kakao fotoğraflarından oluşturmuşlardır. Hastalık tespiti, görüntü analizi ve sınıflandırma için dört CNN modeli eğitmişlerdir. Bunlar; CenterNet ResNet50 V2, EfficientDet D0, SSD MobileNet V2 ve SSD ResNet50 V1 FPN' dir. Daha sonra Black Pod, Swollen Shoot ve sağlıklı kakao olmak üzere üç sınıfı eğitmişlerdir. En iyi performans gösteren model, %80'den fazla güven algılama puanına sahip SSD MobileNet V2 olmuřtur.

2.3.5. An app to assist farmers in the identification of diseases and pests of coffee leaves using deep learning

Bu çalışmanın[11] amacı, farklı yaprak lezyonları için segmentasyon ve sınıflandırma yapabilen etkili ve pratik bir sistem sunmak ve kahve yapraklarındaki biyotik maddelerin hacimsel sinir ağlarını kullanarak yarattığı stres şiddetinin tahmin edilmesi olmuřtur. Önerilen yaklaşım iki aşamadan oluşur: Önem hesaplaması ve belirti lezyon sınıflandırma aşaması olan bir semantik segmentasyon aşaması. Her aşama ayrı ayrı test edilmiş ve her birinin pozitif ve negatif noktaları vurgulanmıştır. Önem tahmini için çok iyi sonuçlar elde etmişlerdir ve modelin önem derecesi değerlerini gerçekte değerlere çok yakın tahmin edebileceğini öne sürmüşlerdir. Biyotik gerilim sınıflandırması için doğruluk oranları %97'den daha yüksekti. Elde edilen ümit verici sonuçlar nedeniyle Android için bir Uygulama geliştirilmiş ve uygulanmıştır. Bu uygulama, akıllı telefon tarafından elde edilen kahve yapraklarının görüntülerini kullanarak hem uzmanlara hem de çiftçilere biyotik gerilimleri tanımlamada ve ölçmede yardımcı olmak için semantik segmentasyon ve önem hesaplaması ve belirti sınıflandırmasından oluşmuřtur.

3. Tartışma ve Sonuçlar

Bitkilerin yaprak hastalıklarından kaynaklanan üretim kaybının en iyi çözümü olarak derin öğrenme ile bitkilerin yaprak hastalıklarının tespiti olarak görülüyor. Bu nedenle en iyi yöntem olan image recognition için en iyi model olan Convolutional Neural Network (CNN) ve onun türevleri (örn. Deep Convolutional Neural Network gibi) olduğu çalışmalar sonucu kabul edilmiştir. İncelediğimiz makalelerde kullanılan modellerin ortalama doğruluk değeri %94 gibi yüksek bir değerdir. Bu yüzden bir CNN modeli geliştirmeyi hedefliyoruz. Bitki hastalıklarının sınıflandırma sorununda en yaygın kullanılan ve bizim de kullanmak istediğimiz mimarilerden bazıları ise şunlardır: AlexNet, GoogLeNet, VGG16, ResNet50, MobileNetv2, VGG19'dur. Veri seti için araştırmacılar ya kendi veri setlerini oluşturmuşlar ya da hazır veri seti kullanmışlardır. Bizim projemiz için kendi veri setimizi oluşturabilmek için yeterli zaman olmadığından hazır veri setleri arasından en çok tercih edilen ve başarılı olan PlantVillage veri setini kullanmayı planlıyoruz.

4. Kaynaklar

1. Pandian, J., N. R. Rajalakshmi, and G. Arulkumaran. "An Improved Deep Residual Convolutional Neural Network for Plant Leaf Disease Detection." *Computational Intelligence & Neuroscience* (2022).
2. Sujatha, R., Chatterjee, J. M., Jhanjhi, N. Z., & Brohi, S. N. (2021). Performance of deep learning vs machine learning in plant leaf disease detection. *Microprocessors and Microsystems*, 80, 103615.
3. Bhattania Y., Singhal P. & Agarwal T. "Plant leaf disease detection using deep learning." *International Journal for Research in Applied Science & Engineering Technology (IJRASET)* Volume 10, 2022
4. Latif, Ghazanfar, et al. "Deep Learning Utilization in Agriculture: Detection of Rice Plant Diseases Using an Improved CNN Model." *Plants* 11.17 (2022): 2230.
5. Xu, M., Liu, J., Liu, Y., Lin, F. X., Liu, Y., & Liu, X. "A first look at deep learning apps on smartphones" In *The World Wide Web Conference* (2019, May).(pp. 2125-2136).
6. Kumi, S., Kelly, D., Woodstuff, J., Lomotey, R. K., Orji, R., & Deters, R. "Cocoa Companion: Deep Learning-Based Smartphone Application for Cocoa Disease Detection" *Procedia Computer Science*, 203, 87-94 (2022).

7. Ahmed, A. A., & Reddy, G. H. (2021). A mobile-based system for detecting plant leaf diseases using deep learning. *AgriEngineering*, 3(3), 478-493.
8. Uzhinskiy, A., Ososkov, G., Goncharov, P., & Nechaevskiy, A. (2019). Multifunctional platform and mobile application for plant disease detection. In *CEUR Workshop Proc* (Vol. 2507, pp. 110-114).
9. M. Sardogan, A. Tuncer and Y. Ozen, "Plant Leaf Disease Detection and Classification Based on CNN with LVQ Algorithm," *2018 3rd International Conference on Computer Science and Engineering (UBMK)*, 2018
10. Ngugi, L. C., Abdelwahab, M., & Abo-Zahhad, M. (2020). Tomato leaf segmentation algorithms for mobile phone applications using deep learning. *Computers and Electronics in Agriculture*, 178, 105788.
11. Esgario, J. G., de Castro, P. B., Tassis, L. M., & Krohling, R. A. (2022). An app to assist farmers in the identification of diseases and pests of coffee leaves using deep learning. *Information Processing in Agriculture*, 9(1), 38-47.